

# Inferência Causal e Políticas Públicas Baseadas em Evidências: Uma Breve Introdução

Danilo Freire

1º de Abril de 2021



[daniolofreire.github.io](https://daniolofreire.github.io)



daniolofreire@gmail.com



[github.com/daniolofreire/apmbb-2021](https://github.com/daniolofreire/apmbb-2021)

# Temas

- Por que precisamos de políticas públicas baseadas em evidências?
- Correlação, causas e efeitos
- Experimentos: a melhor ferramenta de análise estatística
- Separando correlação de causalidade em dados não-experimentais
  - Variáveis de controle
  - Regressão descontínua
  - Controle sintético
- Perguntas dos participantes

# Políticas públicas baseadas em evidências

# Breve contexto

- Nos últimos 20 anos, as ciências sociais têm se dedicado cada vez mais à análise de relações de causa e efeito
- Historicamente, problemas de causalidade reversa e de falsas correlações dificultam o trabalho dos pesquisadores
  - Crescimento econômico e violência: qual dos dois vem primeiro?
  - Diferenças climáticas entre os países explicam níveis de desenvolvimento social?
- Tais problemas motivaram o uso de novos *modelos* de análise de dados
- Grande mudança no paradigma de pesquisa:
  - Maior precisão a respeito dos efeitos causais
  - Uso de técnicas experimentais e quase-experimentais

# O que são políticas públicas baseadas em evidências?

- A busca por maior rigor nas ciências sociais também chegou à administração pública
- Políticas baseadas em evidência são aquelas que *buscam resultados objetivos, utilizando as melhores técnicas disponíveis, para resolver um problema de ordem pública*
- Se contrapõem a análises fundamentadas no senso comum, na intuição e nas ideologias
- A meta é trazer maior eficiência e neutralidade na tomada de decisões dos agentes públicos
- Têm ganhado espaço significativo em diversos países, tais como os EUA e a Grã-Bretanha

# Exemplos

# Exemplos



About Our Work ▾ Members Resources ▾ Contact

Featured Resources

## Community Policing: What works? Where? And will it work in other contexts?

October 15, 2020

### Community Policing: What works? Where? And will it work in other contexts?

On October 15, [Innovations for Poverty Action](#) (IPA) and EGAP co-hosted a community policing roundtable event.

**Can community policing programs be used effectively to build citizen trust in the police and reduce crime?** That question was behind a coordinated research effort of six studies of community policing programs that were simultaneously implemented across six countries—Brazil, Colombia, Liberia, Pakistan, the Philippines, and Uganda. This event shared the results of the research and engaged with sector experts to discuss implications for policy.

# Exemplos



U.S. DEPARTMENT OF JUSTICE  
OFFICE OF JUSTICE PROGRAMS

Contact Us | Careers | Subscribe | 

Search 

About Us News Center Grants/Funding For Congress NCJRS Library Topics Training Data

[Home](#) / [About NCJRS](#) / [Virtual Library](#)

## Growth of Randomized Experiments in Policing: The Vital Few and the Salience of Mentoring

**NCJ Number:** 247515

**Journal:**

*Journal of Experimental Criminology* Volume: 10 Issue: 1 Dated: March 2014

Pages: 1-28

**Author(s):**

Anthony A. Braga; Brandon C. Welsh; Andrew V. Papachristos; Cory Schnell;  
Leigh Grossman

**Date Published:** March 2014

### Downloads

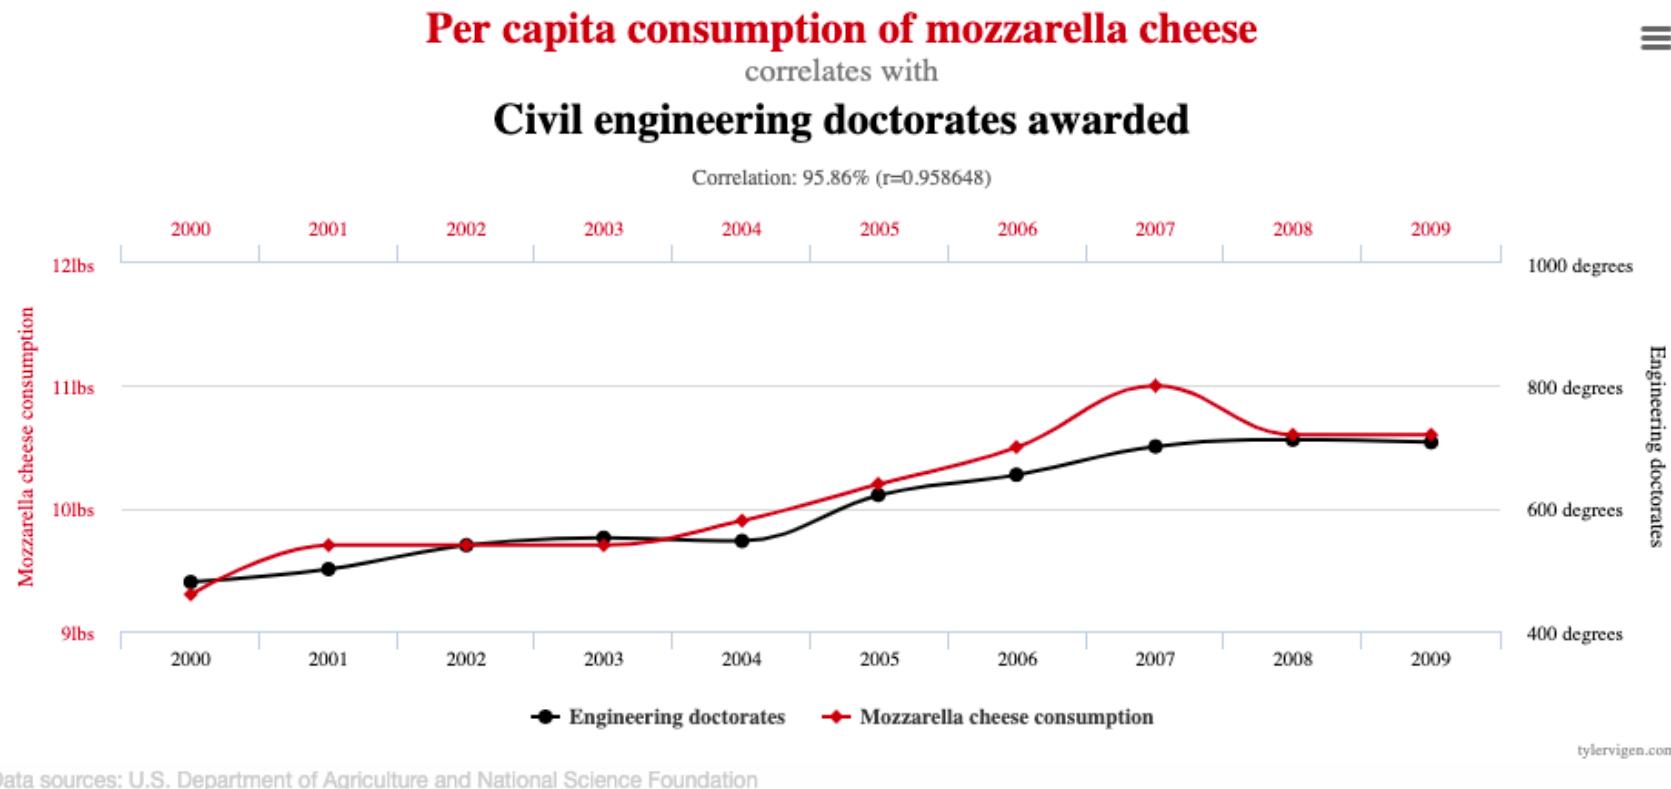
Length: 28 pages



**Correlações, causas e efeitos: como saber o  
que realmente importa?**

# Correlação não é causalidade

- Não é porque duas variáveis estão associadas que uma causa a outra



# O que é uma relação de causa e efeito?

- Uma relação causal tem as seguintes características:
  - *Associação permanente*: "Se  $X$  aumenta ou diminui,  $Y$  tende a aumentar ou diminuir"
  - *Diferença contrafactual*: "Se  $X$  não existisse,  $Y$  seria maior ou menor"
  - *Manipulação*: "Sempre que alguém aumentar ou diminuir  $X$ ,  $Y$  vai ter um valor maior ou menor" (temporalidade)
  - **Não existe causalidade sem variação**
- " $X$  causa  $Y$ " não implica que  $A$  ou  $B$  não causem  $Y$  também;  $X$  é parte da história, mas não necessariamente toda a história
- " $X$  causa  $Y$ " pode ser "Com  $X$ , a probabilidade de  $Y$  é maior ou menor do que sem  $X$ ." ou "Sem  $X$  não há  $Y$ ". As duas interpretações são possíveis

# Resultados potenciais

- Para cada unidade no experimento -- uma pessoa, um bairro, um grupo -- existem dois resultados possíveis após o tratamento:  $Y_i(1)$  e  $Y_i(0)$
- $Y_i(1)$  é o resultado que seria observado se a unidade recebesse o tratamento ( $T_i = 1$ )
- $Y_i(0)$  é o resultado que seria observado se a unidade não recebesse o tratamento ( $T_i = 0$ )
- O efeito causal do tratamento, portanto, é  $\tau_i = Y_i(1) - Y_i(0)$
- **Problema fundamental da inferência causal:** um indivíduo não pode receber e não receber o tratamento *ao mesmo tempo*, assim é impossível estimar o efeito causal para cada pessoa
- Assim, utilizamos o *efeito médio do tratamento* como substituto:
  - $\bar{\tau}_i = \frac{1}{N} \sum_{i=1}^N (Y_i(1) - Y_i(0)) = \overline{Y_i(1)} - \overline{Y_i(0)}$

# Variáveis omitidas e viés de seleção

- O efeito causal médio nos permite saber o quanto as unidades são impactadas pelo tratamento
- Contudo, as unidades precisam ser comparáveis para que o efeito seja uma medida útil e correta
- Comparar grupos que são sistematicamente diferentes produz uma estimativa enviesada do efeito causal
  - Efeito do Bolsa Família sobre educação infantil nos Jardins e no Capão Redondo
  - Efeito de policiamento comunitário no Rio de Janeiro e no Amazonas
- Damos o nome de *variáveis omitidas* aqueles fatores que fazem os casos não serem comparáveis
- A distorção na escolha de unidades para comparação se chama *viés de seleção*

# Variáveis omitidas e viés de seleção

- Assim, para que as políticas públicas sejam efetivas, elas devem ser desenhadas de modo a evitar viés de seleção
- Com viés de seleção, os resultados (sejam positivos ou negativos) podem ser causados por outros fatores que *não* os desejados
- Há uma série de técnicas que buscam reduzir o efeito de variáveis omitidas:
  - Estudos observacionais: regressão com variáveis de controle, regressão descontínua
  - Experimentos
- A idéia de todos estes métodos é criar *unidades que sejam comparáveis*, assim pode-se afirmar com maior certeza que o efeito é realmente causado pelo tratamento

# Experimentos aleatorizados: o padrão-ouro da inferência causal

# Por que usar experimentos?

- Nos experimentos, o tratamento é distribuído aleatoriamente entre os indivíduos
- Como o tratamento foi dado pelo pesquisador, ele é independente de qualquer outra variável *por construção*
- Com isso, não existe variável omitida nem viés de seleção na análise de experimentos
- Caso a amostra utilizada seja representativa da população, pode-se imaginar que o efeito seria o mesmo para todo o grupo
- **Experimentos aleatórios são a melhor forma de garantir que o efeito obtido é causado apenas pelo tratamento**
- Condições: tratamento é a única causa da mudança entre grupos, sem interferência do grupo de tratamento no de controle

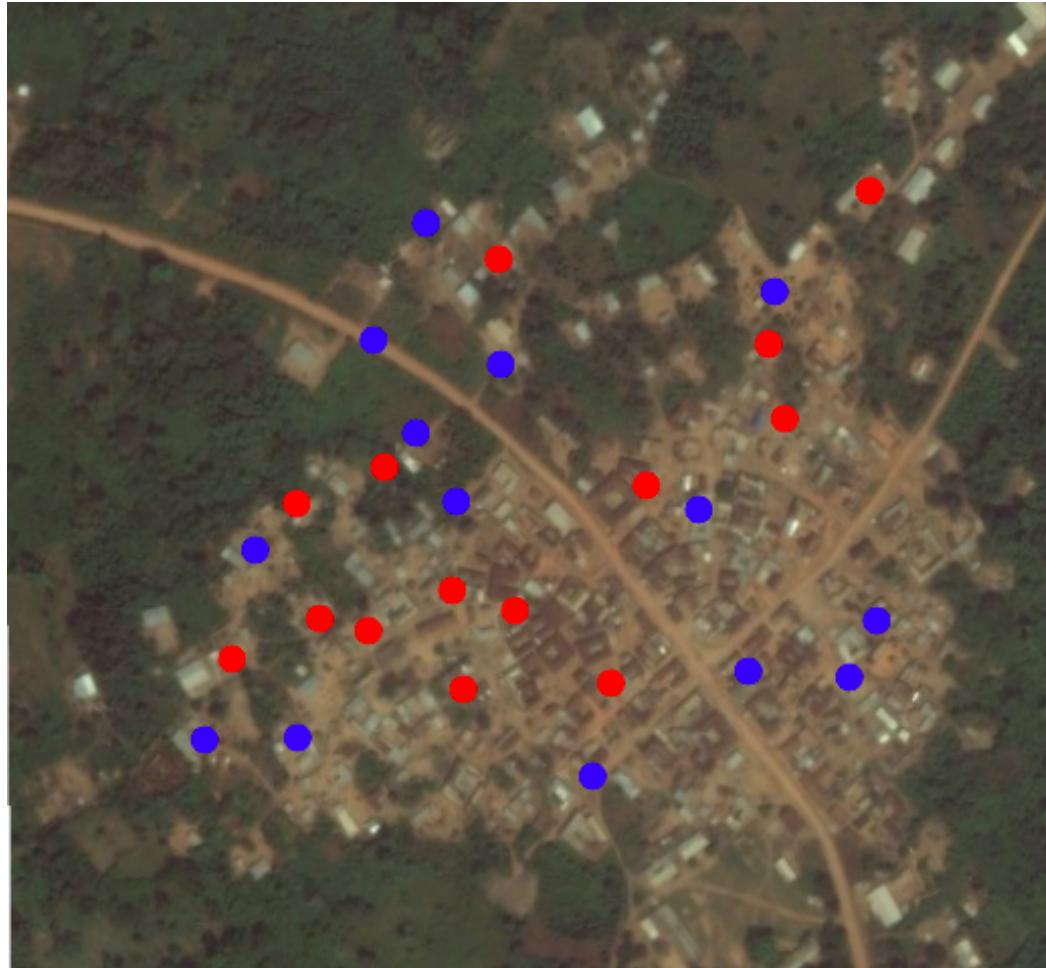
# Amostra aleatória e tratamento aleatório

- Amostra aleatória de domicílios



# Amostra aleatória e tratamento aleatório

- Escolha aleatória dos grupos de controle e tratamento



# Exemplo: policiamento de "hot spots" em Minneapolis

Articles

## General deterrent effects of police patrol in crime “hot spots”: A randomized, controlled trial

Lawrence W. Sherman & David Weisburd

Pages 625-648 | Published online: 18 Aug 2006

[Download citation](#) <https://doi.org/10.1080/07418829500096221>

[References](#) [Citations](#) [Metrics](#) [Reprints & Permissions](#) [Get access](#)

Many criminologists doubt that the dosage of uniformed police patrol causes any measurable difference in crime. This article reports a one-year randomized trial in Minneapolis of increases in patrol dosage at 55 of 110 crime “hot spots,” monitored by 7,542 hours of systematic observations. The experimental group received, on average, twice as much observed patrol presence, although the ratio displayed wide seasonal fluctuation. Reductions in total crime calls ranged from 6 percent to 13 percent. Observed disorder was only half as prevalent in experimental as in control hot spots. We conclude that substantial increases in police patrol presence can indeed cause modest reductions in crime and more impressive reductions in disorder within high crime locations.

### Related

#### People also read

Just enough crime and optimizing spots >

Christophe Justice Quar  
Published on

The Effects of Crime: An Integrative Meta-analysis

# Tratamento

## *Random Assignment*

The final sample of 110 address clusters was assigned randomly to two groups of 55 by the independent statistician, who used a computerized pseudo-random number generator to allocate the clusters equally to two groups. The allocation was performed in five

## *Dosage*

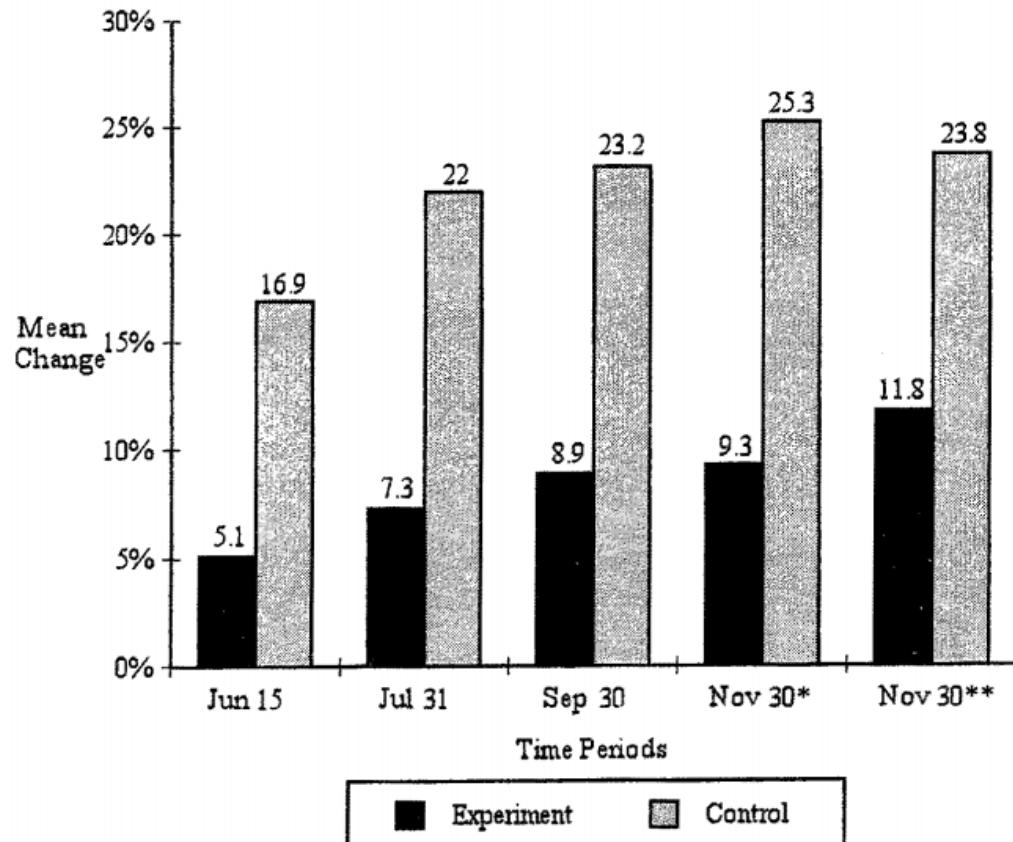
After extensive debate, the police department committed itself to (but never fully achieved) a goal of three hours a day of patrol presence at each of the 55 target hot spots. The dosage, based on the above analysis of “hot times,” was to be divided evenly between the 11-7 and the 7-3 time periods, and was to be provided seven days a week. To enhance the power of the experiment (Weisburd

## *Outcome Measures*

We collected two primary outcome measures: calls about crime and observed disorders. The hot spots were selected on the basis of telephone calls about criminal activity reported by the public—as distinct from dispatchers’ records of events reported by police officers over the radio, which also can generate a “call” record. Therefore citizen calls should be treated as the primary outcome measure. Calls about “soft” and “hard” crime were counted for the

# Resultados

**Figure 3. Percentage Change From Baseline to Experimental Year in Total Crime Calls Per Hot Spot by Treatment Group and Period.**



# **Estudos observacionais: como criar grupos comparáveis**

# O que fazer quando o tratamento não foi aleatorizado?

- Estudos observacionais têm muito mais risco de viés de seleção
- Como o tratamento não foi dado pelos pesquisadores, ele pode ser apenas *observado*, mas não *manipulado*
- Desta forma, precisamos fazer ajustes nos modelos para tornar as unidades compatíveis
- Três formas:
  - Incluir variáveis de controle
  - Usar descontinuidades e analisar casos próximos
  - Criar um grupo de controle artificial parecido com o grupo de tratamento

# Regressão com variáveis de controle

- Tipo mais comum de análise estatística com mais de uma variável
- Pesquisadores incluem *variáveis de controle* para eliminar a influência de certos fatores
- Ao adicionar uma variável, o modelo compara casos com o *valor médio de cada fator  $X$*
- $$Y = \alpha + \beta T + \gamma X + \epsilon$$
- Problemas:
  - Podemos controlar pelas variáveis que conhecemos, não pelas que *não sabemos ou não medimos* (variáveis omitidas)
  - Nem sempre é claro para os pesquisadores quais variáveis devem ser incluídas
  - A inclusão de variáveis desnecessárias piora os modelos

# Exemplo: fatores que influenciam criminalidade globalmente

Journal of Quantitative Criminology

<https://doi.org/10.1007/s10940-021-09501-0>

---

ORIGINAL PAPER



## Global Crime Patterns: An Analysis of Survey Data from 166 Countries Around the World, 2006–2019

Jan van Dijk<sup>1</sup> · Paul Nieuwbeerta<sup>2</sup> · Jacqueline Joudo Larsen<sup>3</sup>

Accepted: 19 February 2021  
© The Author(s) 2021

# Exemplo: fatores que influenciam criminalidade globalmente

**Table 8** Relationship between countries' country characteristics and levels of crime: results of OLS-regression models

	Theft		Violence		Theft and/or Violence		ln(Homicide)		Organised Crime	
	N = 149		N = 148		N = 148		N = 132		N = 149	
	B	S.E.	B	S.E.	B	S.E.	B	S.E.	B	S.E.
(Constant)	.166	.012	.096***	.007	.259***	.018	5364	2.502	71,840***	2387
Motivational factors										
Poverty	.002	.000	.001***	.000	.003***	.001	-.109	.075	-.055	.076
Inequality	.012	.005	.014***	.003	.028***	.008	2021	.988	4448***	1062
Youth	.006	.002	.002*	.001	.009***	.003	1048***	.336	-.159	.364
Opportunity related factors										
Wealth	-.001	.011	-.007	.006	-.004	.016	-.200	2.019	-3186	2096
Urbanisation	.001	.000	.001***	.000	.002***	.001	.058	.070	.017	.075
Governance										
Governance_Fragile_State	.061	.012	.046***	.007	.108***	.017	7363***	2.057	26,808***	2672
Governance_Failed_State	.049	.016	.057***	.009	.106***	.023	3375	3.032	34,192***	3073
Governance	.008	.005	.003	.003	.009	.008	1837	.944	-3290***	1008
R-sq	.72		.77		.77		.47		.79	

Correlates are centered around their means in their group of countries, i.e. failed, fragile or effective states

\* $p < .10$ , \*\* $p < 0.05$ , \*\*\* $p < 0.01$ ; Listwise deletion of missing values

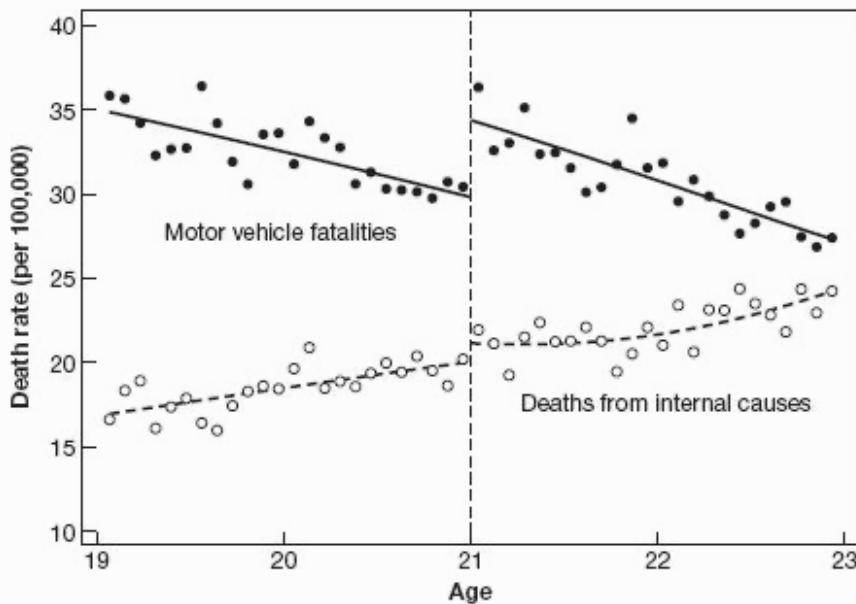
# Regressão descontínua

- Outra forma de obter grupos comparáveis consiste em buscar uma descontinuidade e analisar as pessoas bem próximas ao corte
- Mudanças causadas por vários motivos: leis, requerimentos, etc
- Tratamento ocorre quando a pessoa está apenas *de um lado* do corte
- Método quase tão eficiente quanto experimentos: casos próximos são geralmente muito comparáveis
- Premissas:
  - As pessoas não podem escolher em qual lado do corte elas estarão
  - Apenas grupos próximos ao corte podem ser comparados: menor poder de generalização

# **Exemplo: efeito do consumo de álcool na mortalidade de jovens**

# Exemplo: efeito do consumo de álcool na mortalidade de jovens

FIGURE 4.5  
RD estimates of MLDA effects on mortality by cause of death



Notes: This figure plots death rates from motor vehicle accidents and internal causes against age in months. Lines in the figure plot fitted values from regressions of mortality by cause on an over-21 dummy and a quadratic function of age in months, interacted with the dummy (the vertical dashed line indicates the minimum legal drinking age [MLDA] cutoff).

# Controle sintético

- Em muitos casos, não há como realizar um experimento aleatório ou buscar uma descontinuidade existente
- Uma solução é criar um grupo de controle artificial que seja muito parecido com o grupo de tratamento
- A meta é, novamente, estabelecer uma comparação adequada
- *Controle sintético* é um método que atribui pesos para unidades diferentes do grupo de controle
- Utilizado para medir diferenças no tempo
- Matematicamente complexo mas muito intuitivo

# Exemplo: efeito das políticas de redução de homicídio em São Paulo



Latin American  
Research Review

Freire, Danilo. 2018. Evaluating the Effect of Homicide Prevention Strategies in São Paulo, Brazil: A Synthetic Control Approach. *Latin American Research Review* 53(2), pp. 231–249. DOI: <https://doi.org/10.25222/larr.334>

---

## POLITICS AND INTERNATIONAL RELATIONS

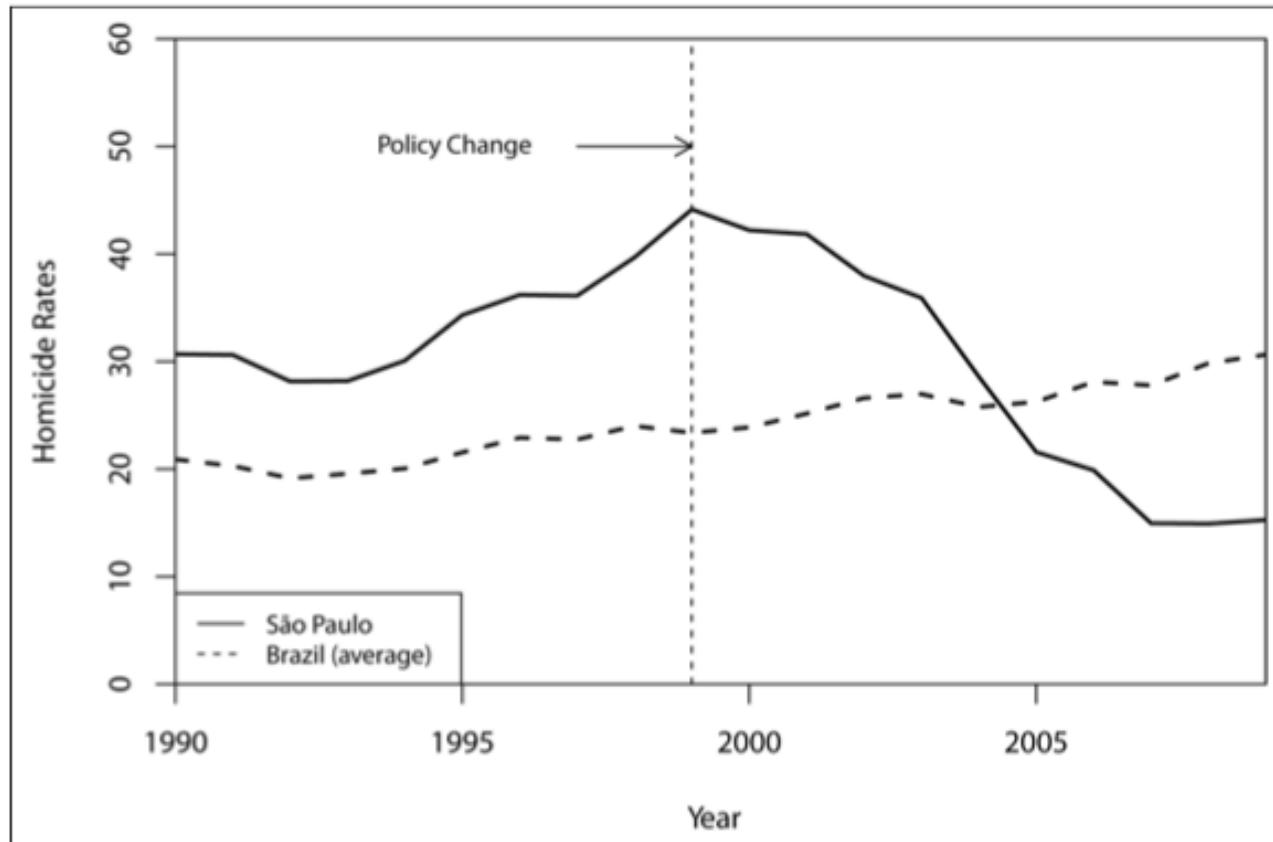
### Evaluating the Effect of Homicide Prevention Strategies in São Paulo, Brazil: A Synthetic Control Approach

Danilo Freire

King's College London, GB

[daniolofreire@gmail.com](mailto:daniolofreire@gmail.com)

# Exemplo: efeito das políticas de redução de homicídio em São Paulo



**Figure 1:** Homicide rates per 100,000 population: São Paulo and Brazil (excluding the state of São Paulo).  
Data from Instituto de Pesquisa Econômica Aplicada, <http://www.ipeadata.gov.br/>.

# Exemplo: efeito das políticas de redução de homicídio em São Paulo

**Table 1:** Synthetic weights for São Paulo.

State	Synthetic Control Weights	Predictor	Weights
Santa Catarina	0.274	Years of Schooling	0.469
Distrito Federal	0.210	State GDP per Capita	0.275
Espírito Santo	0.209	Homicide Rate	0.241
Rio de Janeiro	0.169	Population Living in Extreme Poverty	0.009
Roraima	0.137	Gini Index	0.005
Pernambuco	0.001	Natural Logarithm of State Population	0.001

# Exemplo: efeito das políticas de redução de homicídio em São Paulo

**Table 2:** Homicide rate predictor means before policy implementation.

Predictor	São Paulo	Synthetic São Paulo	Sample Mean
Years of Schooling	6.089	6.110	4.963
State GDP Per Capita	23.285	23.079	11.830
Homicide Rate	32.672	32.479	21.843
Population Living in Extreme Poverty	0.054	0.082	0.185
Gini Index	0.536	0.561	0.578
Ln Population	17.335	14.838	14.867
State GDP Growth	1.330	2.585	3.528

# Exemplo: efeito das políticas de redução de homicídio em São Paulo

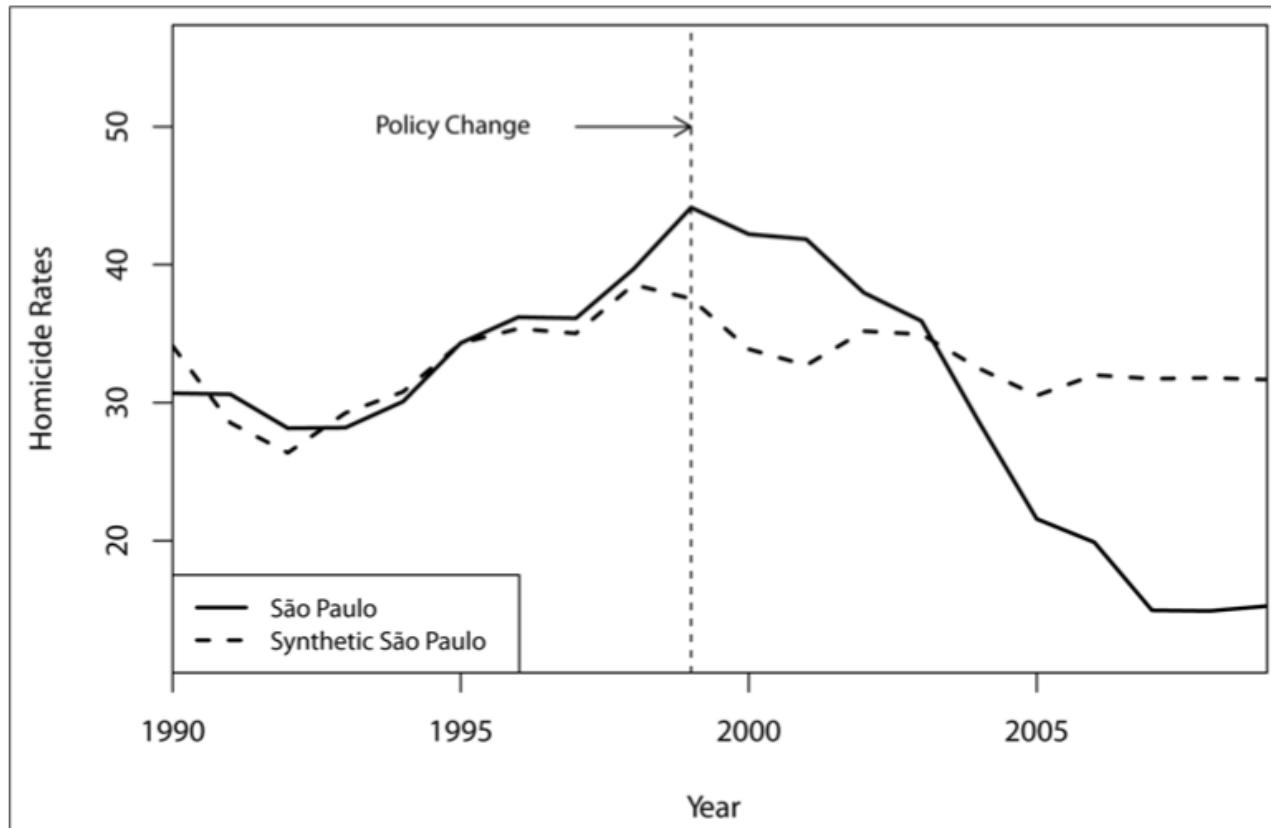


Figure 2: Trends in homicide rates: São Paulo versus synthetic São Paulo.

# Resumo

- Políticas públicas baseadas em evidências são mais rigorosas, mais confiáveis, mais efetivas e menos ideológicas
- A força da evidência estatística vem da capacidade de diferenciar causa e efeito com clareza
- Experimentos são a melhor maneira para testar a eficácia de uma política
- A aleatorização do tratamento é o modo pelo qual asseguramos que a análise não tem viés de seleção nem variáveis omitidas
- Quando experimentos não são possíveis, seja por motivos práticos ou éticos, devemos analisar dados observacionais

# Resumo

- Correlações não implicam causalidade
- Em dados observacionais, é preciso garantir que os grupos sejam comparáveis, o que não é tarefa fácil
- Pode-se incluir variáveis adicionais aos modelos de regressão
- Pode-se também buscar por descontinuidades jurídicas, populacionais, geográficas, etc, e analisar casos próximos
- Por fim, na ausência de grupos comparáveis, podemos criar um grupo de controle sintético e estimar o impacto de um tratamento no tempo

# Sugestões de leitura

- Joshua Angrist e Stephen Pischke. *Mastering 'Metrics: The Path from Cause to Effect*. Princeton University Press, 2014.
- Jake Bowers e Paul Testa. "Better Government, Better Science: The Promise of and Challenges Facing the Evidence-Informed Policy Movement". *Annual Review of Political Science*, 2019.
- Nancy Cartwright e Jeremy Hardie. *Evidence-Based Policy: A Practical Guide to Doing It Better*. Oxford University Press, 2012.
- Alan Gerber e Donald Green. *Field Experiments: Design, Analysis, and Interpretation*. Norton Books, 2012.
- Paul Holland. "Statistics and Causal Inference". *Journal of the American Statistical Association*, 81:945–960, Dezembro de 1986.

# Sugestões de leitura

- Guido Imbens and Donald Rubin. *Causal Inference in Statistics, Social, and Biomedical Sciences*. Cambridge University Press, 2015.
- Stephen Morgan e Christopher Winship. *Counterfactuals and Causal Inference: Methods and Principles for Social Research*. Cambridge University Press, 2014.
- Judea Pearl. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, 2000.
- Judea Pearl e Dana Mackenzie. *The Book of Why: The New Science of Cause and Effect*. Basic Books, 2018.
- Thomas Richardson e James Robins. "Single World Intervention Graphs (swigs): A Unification of the Counterfactual and Graphical Approaches to Causality". Center for the Statistics and the Social Sciences, University of Washington Series. Working Paper, 128(30), 2013.

Muito obrigado!

# Contato

- Danilo Freire:
  - [dani洛freire@gmail.com](mailto:dani洛freire@gmail.com)
  - <http://dani洛freire.github.io>
  - <http://github.com/dani洛freire/apmbb-2021>